Многомерное Индексирование (Лекция 12)

Многомерное Индексирование

v2

Георгий Чернышев

Академический Университет chernishev@gmail.com

20 ноября 2017 г.

План

- Индексирование.
- Одномерное индексирование: В+-дерево.
- Многомерное индексирование
 - Введение
 - Двухшаговая схема
 - Запросы
 - R-дерево
- Методы разделения пространства на примере KD дерева
- Locality-Sensitive Hashing



Индекс

Способ ускорения доступа к данным, обычно какое-то упорядочивание.

- Используются древовидные структуры B^+ -tree, R-tree;
- Не всегда выгодно использовать: занимает место и может ухудшить общую производительность на обновлениях;
- Выбор атрибута (-ов) для индексирования отдается на откуп администратору СУБД;
- Существует много концептуально разных типов индексов.

B^+ -tree (1)

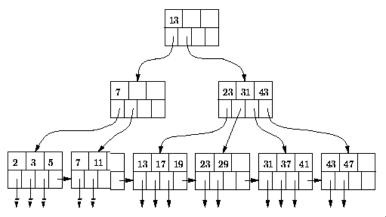
 \ni то вариант B-tree, отличия:

- Все ключи в листьях;
- Листья прошиты для итерирования по данным;
- Все уровни кроме листового должны (хорошо было бы) чтобы помещались в оперативную память.

Используются во всех индустриальных (и большинстве игрушечных) СУБД.

B^+ -tree (2): пример

A B+ Tree



1

¹Изображение взято с http://infolab.stanford.edu/ ullman/dbsi/win98/hw2.html > ∢ ≣ > ∢ ≣ > > ∃ → へ Q С

О реализации

- На самом деле она очень сложна!
- Надо думать о физическом представлении, тюнингу под кеш-память, параллельном доступе, восстановлении и прочей интеграции с другими подсистемами СУБД.
- Пример: достаточно игрушечный индекс на B^+ -tree это около 50 килобайт кода.

Многомерное индексирование

Индексирование N-мерном пространстве:

- Что индексируем:
 - Точки;
 - Объекты.
- Для чего индексируем:
 - СУБД;
 - GIS-системы (их, кажется, побольше будет).
- Двухшаговая схема:
 - Фильтрация, получение списка кандидатов;
 - Проверка списка кандидатов, очистка от ложных срабатываний.

Двухшаговая схема

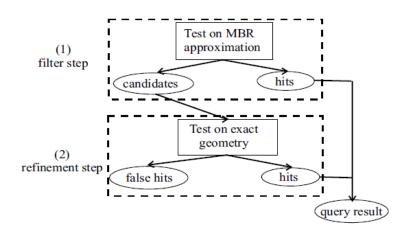


Fig. 4.2. Two-step query processing procedure.

Запросы

Индекс разрабатывется под запросы [Manolopoulos et al., 2005]:

- Запрос на диапазон;
- Топологические запросы;

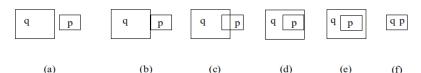


Fig. 4.3. Topological relations: (a) $\operatorname{disjoint}(q,p)$; (b) $\operatorname{meet}(q,p)$; (c) $\operatorname{overlap}(q,p)$; (d) $\operatorname{covers}(q,p)$; (e) $\operatorname{contains}(q,p)$ or $\operatorname{inside}(p,q)$; (f) $\operatorname{equal}(q,p)$.

- Запросы на направление;
- Запросы к ближайшим соседям (разные варианты: прямые, обратные, условные и т.д.);
- Запросы с пространственным соединением.

R-tree (1)

- Древовидная структура для упрощения поиска;
- Можно сказать что это обобщение B^+ -tree на многомерный случай;
- Используется в индустриальных СУБД и GIS системах: PostgreSQL, Oracle, SQLite, PostGIS, MapInfo, ...
 - фактически индустриальный стандарт для многомерных данных малой размерности;
- Есть в Boost и куче других приложений, вне СУБД.

R-tree (2): популярность

Table	1.1.	Access	methods	covered	in	this	book,	ordered	by	year	οĒ	publication	

Year	Access Method	Authors and References
1994	Hilbert R-tree	Kamel, Faloutses [105]
1994	R-link	Ng, Kameda [161]
1994	TV-tree	Lin, Jagadish, Falouteos [138]
1996	OR-tree	Manolopoulos, Nardelli, Panadopoulos, Projetti [146]
1000	SS-tree	White, Jain 2451
1995	VAMSplit R-tree	White, Jain 244
100%	X-tree	Berchtold, Keim, Kriegel 2241
1996	3D R-tree	Theodoridis, Vazirgiannis, Sellis [238]
1997	Cubtree	Rosseopoulos, Kotidis [199]
1997	Linear Node Splitting	Ang, Tan [11]
1997	S-tree	Aggrawal, Wolf, Wu. Epelman [5]
1997	SRatnee	Katayama, Satoh [108]
1997	STR R-tree	Leutenogger, Edgington, Lopez [134]
1998	Ritemporal R-tree	Kumar, Teotras, Falouteos [125]
1995	HR-tree	Nascimento, Silva 158, 159
1995	Optimal Node Splitting	Garcia, Lopez, Leutenegger [71]
1998	Ra-tree	Juergens, Long [102]
1998	STLT	
		Chen, Chouboy, Rundensteiner [42]
	TGS	Garcia, Lopez, Leutenegger [70]
1900	GBI	Choubey, Chen, Rundensteiner [47]
1999	R ^{ET} -tree	Saltenis, Jensen [201]
1900	2+3 R-tree	Nascimento, Silva, Theodoridis [159]
	Branch Grafting	Schrok, Chen [208]
2000	Bitmap R-tree	Ang, Tan [12]
2000	TB-tree	Pfoser, Jensen, Theodoridis [189]
2000	TPR-tree	Saltenis, Jensen, Leutenegger, Lopez [202]
2001	all-tree	Paradias, Kanlis, Zhang, Tao 1700
2001	Ben-tree	Agarwal, deBerg, Gudmundsson, Hammar, Haverkort [4]
2001	Compact R-tree	Huang, Lin, Lin [93]
2001	CR-tree	Kim, Cho, Kwon [110]
2001	Efficient HR-tree	Tao, Papadies [222]
2001	MV3R-tree	Tao, Panadias 221
2001	PPR-tree	Kollios, Tsotras, Generoukos, Delis, Haditeleftheriou [113]
2001	BS-tree	Park, Heu, Kim [184]
2001	SOM-based R-tree	Oh, Feng, Kanelo, Makinouchi [162]
2001	STAR-tree	Proconiuc, Agarwal, Har-Poled, 1922
2002	aP-tree	Tao, Panadias, Zhang, 12281
2002	Buffer R-tree	Arge, Hinrichs, Vahrenhold, Vitter, [16]
2002	cRatron	Brakatsoulas, Ploser, Theodoridis, [32]
2002	DR-tree	Driacifothia, Proser, Interdentia, [32]
2002	HMM R-tree	Lee, Chung. [133]
		Jin, Jagadish, [100]
2002	Lazy Update R-tree	Kwon, Lee, Lee, [127]
2002	Low Stabbing Number	deBerg, Hammar, Overnars, Gudmundsson, [56]
2002	VCI R-tree	Prabhakar, Xia, Kalashnikov, Aref, Hambrusch, [191]
2003	FNR-tree	Frontzos, [67]
2003	LR-tree	Bozanis, Nanopoulos, Manolopoulos, [31]
2003	OMT R-tree	Lee, Lee, [131]
2003	Partitioned R-tree	Bozanis, Nanopoulos, Manolopoulos, [31]
2003	Q+R-tree	Xia, Prabhakar, [248]
2003	Seeded Clustering	Lee, Moon, Lee, [132]
2003	SETI	Chakka, Everspaugh, Patel, [18]
	TPR*-tree	Tao, Papadias, Sun. [227]
2003	TR-tree	Park, Lee, 185
2004	Morging R-trees	Vasatitis, Nanopoulos, Bonanis, 12401
2004	MON-tree	Almeida, Gating, [7]
2004	PR-tree	Argo, dellorg, Haverkort, Yi, [15]
2004	BPPF-tree	Pelants, Saltents, Jensen, [188]

Table 1.1. Access methods covered in this book, ordered by year of publicati

rear	Access Method	Authors and References
	R-tree	Guttman [81]
	Packed R-tree	Romeopoulos, Leifker [199]
	R*-tree	Sellts, Roussopoloulos, Faloutsos [211]
	Cell-tree	Guenther [77]
	P-tree	Jagadish, [96] (and 1993 Schiwictz [206]
	R*-tree	Bockmann, Kriegel, Schneider, Seeger 1
	RT-tree	Xu, Han, Lu [249]
	Sphere-tree	Oosterom [164]
	Independent R-trees	Kamel, Faloutses [100]
	MX R-tree	Ramel, Faloutses [100]
	Supernode R-tree	Kamel, Faloutses 103

4 Изображение взято из [Manolopoulos et al., 2005]

R-tree (3): определение

Согласно [Manolopoulos et al., 2005] R-дерево — это древовидная структура данных, заданная парой (m,M) со следующими свойствами:

- Каждый лист может содержать до M записей, минимально $2 \le m \le M/2$.
- Каждая запись в листе представлена в форме (mbr, oid), где mbr это минимальный ограничивающий прямоугольник, а oid идентификатор объекта.
- Количество записей хранящихся во внутреннем узле также должно при- надлежать [m; M]. Каждая запись в узле представляет собой пару (mbr, p), где p указатель на ребенка узла, а mbr содержит в себе mbr ребенка.
- Дерево сбалансировано все листья находятся на одном уровне.

R-tree (4): пример

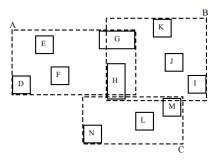


Fig. 1.2. An example of data MBRs and their MBRs.

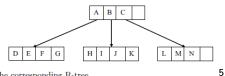


Fig. 1.3. The corresponding R-tree.

4□ > 4♠ > 4 = > 4 = > = 90

R-tree (5): свойства

- Теперь у нас не диапазоны, а "коробочки" многомерные прямоугольники;
- Сложно расщеплять вершину: NP-трудная задача + много критериев;
- Сложно искать, MBR могут пересекаться o надо проверить много путей до листьев;

Вычисление диапазонного запроса

Algorithm RangeSearch(TypeNode RN, TypeRegion Q)

/* Finds all rectangles that are stored in an R-tree with root node RN, which are intersected by a query rectangle Q. Answers are stored in the set \mathcal{A} */

- 1. if RN is not a leaf node
- examine each entry e of RN to find those e.mbr that intersect Q
- foreach such entry e call RangeSearch(e.ptr,Q)
- else // RN is a leaf node
- examine all entries e and find those for which e.mbr intersects Q
- add these entries to the answer set A
- 7. endif

Fig. 1.4. The R-tree range search algorithm.

Вставка в R-tree \perp

Algorithm Insert(TypeEntry E, TypeNode RN)

Inserts a new entry E in an R-tree with root node RN */

- Traverse the tree from root RN to the appropriate leaf. At each level, select the node, L, whose MBR will require the minimum area enlargement to cover E.mbr
- In case of ties, select the node whose MBR has the minimum area
- if the selected leaf L can accommodate E
- 4. Insert E into L
- Update all MBRs in the path from the root to L, so that all of them cover E.mbr
- else //L is already full
- Let \mathcal{E} be the set consisting of all L's entries and the new entry E Select as seeds two entries $e_1, e_2 \in \mathcal{E}$, where the distance between e_1 and e_2 is the maximum among all other pairs of entries from \mathcal{E} Form two nodes, L_1 and L_2 , where the first contains e_1 and the second e_2
- Examine the remaining members of \mathcal{E} one by one and assign them to L_1 or L_2 , depending on which of the MBRs of these nodes will require the minimum area enlargement so as to cover this entry
- 9. if a tie occurs

7

⁷Изображение взято из [Manolopoulos et al., 2005]

Вставка в R-tree | |

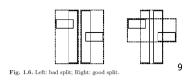
```
10.
           Assign the entry to the node whose MBR has the smaller area
11.
       endif
       if a tie occurs again
13.
           Assign the entry to the node that contains the smaller number of entries
14.
       endif
15.
       if during the assignment of entries, there remain \lambda entries to be assigned
       and the one node contains m - \lambda entries
16.
           Assign all the remaining entries to this node without considering
           the aforementioned criteria.
           /* so that the node will contain at least m entries */
17.
       endif
18.
       Update the MBRs of nodes that are in the path from root to L, so as to
       cover L_1 and accommodate L_2
19.
       Perform splits at the upper levels if necessary
20.
       In case the root has to be split, create a new root
21.
       Increase the height of the tree by one
22. endif
```

Fig. 1.5. The R-tree insertion algorithm.

Задача расщепления вершины

Строки 6–17 на самом деле отдельный алгоритм.

 Много критериев: суммарная площадь, периметр, пересечение и т.д.

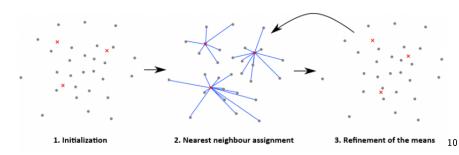


- *NP*-трудная задача, доказано;
- А значит и много подходов к решению: Al-Badarneh's et al. split, Corner-Based split, K-means split, Hilbert split, RR* split, R* split, Greenes split, Guttman Quadratic and Linear splits, Ang and Tan split, Double-Sorting Based split.



⁹Изображение взято из [Manolopoulos et al., 2005]

Применение K-means



- Исходная работа [Brakatsoulas et al., 2002]
- Проблема для сходимости в случае прямоугольников нужно либо доказывать ее, либо нужны:
 - 🚺 правильная метрика расстояния между многоугольниками;
 - правильная формула центроида.
- Математически обоснованное решение [Grigorev and Chernishev, 2016];

[.] Изображение взято из https://prateekvjoshi.com/2013/06/06/what-is∃k-means-clustering/는 >

R-tree: варианты

Основные варианты [Papadopoulos et al., 2009]:

- R^* повторная вставка при расщеплении;
- R^+ объект может покрываться несколькими mbr;
- Гильбертово R-дерево учет точки на гильбертовой кривой;
- Есть более 70 вариантов;

Что бывает еще?

Классификация:

- \bullet Сбалансированные деревья R-tree, RD-tree SR-tree;
- Методы разделения пространства quadtree, Kd-tree, tries;

Реализация в постгрес (обобщенная модель с транзакционностью):

- GiST¹¹;
- SP-GiST¹² [Eltabakh et al., 2006];

¹¹http://www.sai.msu.su/megera/postgres/gist/

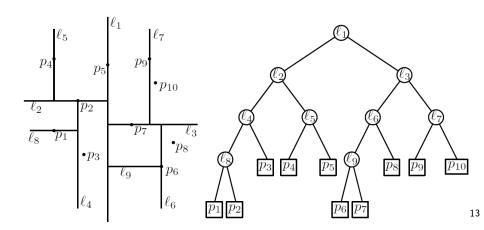
¹²https://www.postgresql.org/docs/9.2/static/spgist-intro.html

Kd-дерево

Суть:

- Имея n-мерный набор точек расщепляем его последовательно по $x_1, x_2, \ldots x_n, x_1, x_2, \ldots;$
- На *i*-м шаге расщепления делим наш набор по медиане *i*-ой координаты на две части, "проводим" черту разбивающая наше пространство на две части;
- На i+1-м шаге аналогично поступаем с каждой половиной точек оставшейся от i-го.

Двумерный пример



¹³ Изображение взято из https://www.cise.ufl.edu/class/cot5520fa09/CG_RangeKDtrees.pdf « 📜 » 📜 💉 🔾 🔾

Как строить

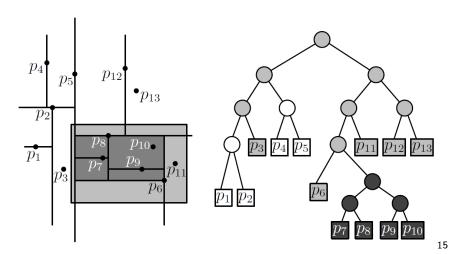
```
Algorithm BUILDKDTREE(P, depth)
     if P contains only one point
        then return a leaf storing this point
3.
        else if depth is even
                  then Split P with a vertical line \ell through the
4.
                         median x-coordinate into P_1 (left of or
                        on \ell) and P_2 (right of \ell)
5.
                  else Split P with a horizontal line \ell through
                        the median y-coordinate into P_1 (below
                        or on \ell) and P_2 (above \ell)
               v_{\text{left}} \leftarrow \text{BUILDKDTREE}(P_1, depth + 1)
6.
7.
               v_{\text{right}} \leftarrow \text{BUILDKDTREE}(P_2, depth + 1)
8.
               Create a node v storing \ell, make v_{\text{left}} the left
               child of v, and make v_{\text{right}} the right child of v.
                                                                         14
9.
```

return v

tns://www.cise.ufl.edu/class/cot5520fa09/CG_RangeKDtrees.pdf

Запросы

Регион либо хранится с каждым узлом, либо вычисляется налету.



ято из https://www.cise.ufl.edu/class/cot5520fa09/CG_RangeKDtrees.pdf

Обработка и исполнение запросов: лек

Как на практике обстоят дела с деревьями?

- С ростом размерности очень сильно растет время построения и время исполнения запросов.
- Что происходит? Приходится проверять всё больший и больший % индекса — curse of dimensionality;
- Например, в 8-ми мерном пространстве поиск может быть в 16 раз медленнее чем в двумерном на индексе с *R*-tree;
- Припарки PCA, SVD и прочее не помогают;
- Математики доказали что это неизбежно для деревьев;

Поэтому, область применения деревьев — R-tree до 10 измерений, отдельные варианты до 30-40 (RR^* -tree). В тоже время, индустрии нужны десятки-сотни тысяч...

Что делать?

Locality-Sensitive Hashing (LSH) [Gionis et al., 1999], суть:

- Имеем набор хеш-функций, они распределяют объекты по ведрам;
- Хеш-функции заданы так, чтобы вероятность коллизии была была максимальна если объекты близки.

Увы:

- Работает только для kNN, дубликатов и еще некоторых типов;
- Не точно, есть оценки.

Вроде как, работает на практике.

Что еще хотелось показать?

- M-tree [Ciaccia et al., 1997] дерево для запросов по подобию с произвольной метрикой;
- ND-tree [Qian et al., 2006] дерево для индексирования неупорядоченных дискретных многомерных значений, например генетических последовательностей.

Но увы, время на исходе :(

Ссылки I



Aristides Gionis, Piotr Indyk, and Rajeev Motwani. 1999. Similarity Search in High Dimensions via Hashing. In Proceedings of the 25th International Conference on Very Large Data Bases (VLDB '99), Malcolm P. Atkinson, Maria E. Orlowska, Patrick Valduriez, Stanley B. Zdonik, and Michael L. Brodie (Eds.). Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 518–529.



Paolo Ciaccia, Marco Patella, and Pavel Zezula. 1997. M-tree: An Efficient Access Method for Similarity Search in Metric Spaces. In Proceedings of the 23rd International Conference on Very Large Data Bases (VLDB '97), Matthias Jarke, Michael J. Carey, Klaus R. Dittrich, Frederick H. Lochovsky, Pericles Loucopoulos, and Manfred A. Jeusfeld (Eds.). Morgan Kaufmann Publishers Inc., San Francisco, CA. USA, 426–435.



Gang Qian, Qiang Zhu, Qiang Xue, and Sakti Pramanik. 2006. Dynamic indexing for multidimensional non-ordered discrete data spaces using a data-partitioning approach. ACM Trans. Database Syst. 31, 2 (June 2006), 439–484. DOI=http://dx.doi.org/10.1145/1138394.1138395

Ссылки II



M. Y. Eltabakh, R. Eltarras and W. G. Aref, "Space-Partitioning Trees in PostgreSQL: Realization and Performance,"22nd International Conference on Data Engineering (ICDE'06), 2006, pp. 100-100. doi: 10.1109/ICDE.2006.146



Sotiris Brakatsoulas, Dieter Pfoser, and Yannis Theodoridis. 2002. Revisiting R-Tree Construction Principles. In Proceedings of the 6th East European Conference on Advances in Databases and Information Systems (ADBIS '02), Yannis Manolopoulos and Pavol Návrat (Eds.). Springer-Verlag, London, UK, UK, 149-162.

Valentin Grigorev and George Chernishev. 2016. K-means Split Revisited: Well-grounded Approach and Experimental Evaluation. In Proceedings of the 2016 International Conference on Management of Data (SIGMOD '16). ACM, New York, NY, USA, 2251–2252. DOI: http://dx.doi.org/10.1145/2882903.2914833

Ссылки III



Yannis Manolopoulos, Alexandros Nanopoulos, Apostolos N. Papadopoulos, and Yannis Theodoridis. 2005. R-Trees: Theory and Applications. Springer Publishing Company, Incorporated.